

— KMoshi (가제) 연구 계획

KMoshi 모델 구현 설계안

2026 AI 챔피언 Submission

01

연구 목표

연구 배경, 문제 정의,
목표 선언

02

컨트리뷰션

기여 주장, 신규성,
기여의 범위

03

아키텍처

기반 구조, 백본 교체,
임베딩 확장

04

파이프라인

데이터 구성 및 KD
설계, Joint Loss

05

단계별 학습 과정

학습 순서 논리,
학습 단계, 검증 계획

Full-duplex 음성대화 모델의 계보

Full-duplex는 "말하면서 동시에 듣는" 실시간 음성 모델.

일본에서는 6만 시간의 학습 데이터로 이 문제를 풀어냄.

2024

Moshi

Mimi 코덱 + Temporal / Depth Transformer
동시 입출력 오디오 스트림



2025 · 일본어

J-Moshi

J-CHAT 코퍼스 69k h > 전처리 후 60k h 학습
+ 스테레오 344 h · TTS 증강 602 h



2025 · 일본어

LLM-jp-Moshi

일본어 LLM 백본 결합 계열 후속 연구

문제 정의

한국어 멀티턴 음성 데이터셋의 부재

Oh

사용 가능한 한국어 멀티턴 대화 오디오 (오픈소스 라이선스 기준)

J-Moshi가 취한 대규모 멀티턴 수집 경로는 한국어로 그대로 복제 불가.
수집 비용 자체가 연구의 병목.

따라서, 문제 정의 교체: "수집" -> "전이"

KMoshi – 한국어 멀티턴 데이터

0시간으로 한국어 full-duplex 구성

사용 데이터

한국어 단일 발화

모노 음성 · GT 코드 CE로 한국어 말소리·내용을 담당.

사용 데이터

영어 멀티턴 (KD)

Teacher = 원본 Moshi · 스테레오 대화에서 턴테이킹·타이밍을 담당.

한국어 멀티턴 대화 데이터를 **쓰지 않고** 한국어 멀티턴 **창발**

논문 기여 4가지

01 한국어 full-duplex 최초 구현. 실시간 상호 발화·중첩·침묵을 처리하는 한국어 음성 대화 모델.

02 영어 > 한국어 멀티턴(턴테이킹) 전이. "행동"이 언어를 건너 전이되는가 - 핵심 기여.

데이터 수집 비용이 비싼 언어별 멀티턴 데이터 없이 음성 턴테이킹이 전이 가능함을 증명 (Data efficient)

그를 위한 아키텍처 변경 제안 (단일 발화 => 싱글턴 => 멀티턴 전이 가능성이 높은 임베딩 구조 제안)

03 Mimi semantic token 기반 일본어 전이 스왑 · 서브 기여

RVQ 토큰라이저에서 명시적으로 분리 설계된 시멘틱 토큰이 해주는 역할을 규명하는 연구

04 J-Moshi 60k h 대비 데이터 효율 정량화 · 서브 기여

"멀티 링구얼 전이는 당연히 되는 것 아닌가?"에 대한 세 가지 답

01 전이 대상이 의미가 아니라 **행동·타이밍**. (멀티 링구얼 전이 x / 턴테이킹 전이 o)

언제 침묵하고, 언제 끼어들고, 언제 맞장구를 치는가: 내용(content)이 아니라 시간적 행동(temporal behavior).

02 음성 full-duplex 모델에서 cross-lingual turn-taking 전이를 다룬 선행연구가 없음.

텍스트 대화의 cross-lingual 전이는 알려져 있으나, 음성에서 검증한 사례가 부재.

03 전이 경로가 단순 파인튜닝이 아니라 두 목적함수의 joint gradient 합성.

한 방향 미세조정이 아니라, 서로 다른 신호를 동시에 흘려 존재하지 않는 조합을 유도.

Research Focus Points

완전 전이에 실패해도 실험이 실패로 끝나지 않음.

턴테이킹의 어느 하위 요소가 언어 독립적인가

: gap 타이밍인가, 오버랩인가, 맞장구인가 / 그 자체가 세부 기여.

보고 지표는 이진(성공/실패)이 아니라 **상한(ceiling)** 대비 도달률.

"어디까지 전이되고 어디서 깨지는가"를 규명하는 것이 이 실험 설계의 목적.

Moshi 해부

코덱

Mimi

24 kHz ↔ 12.5 Hz

프레임당 8 코드북 × 2048

시간축

**Temporal(Helium)
Transformer 7B**

프레임 시퀀스 예측


코드북축

Depth Transformer

한 프레임 내 8개 코드북 순차 예측

신호 흐름

- 01 오디오 파형 > **Mimi 인코더** > 프레임당 8개의 이산 RVQ 토큰
- 02 이중 스트림 유저: 자기 발화와 상대 발화를 병렬 채널로 함께 예측
- 03 Inner Monologue: 시간 정렬된 텍스트 스트림을 병기, PAD·EPAD로 발화 개시·종료를 명시
- 04 Temporal이 시간을, Depth가 프레임 내 8개 번호를 순서대로 예측 > **Mimi 디코더**로 파형 복원




Helium > Qwen3-8B: "한글 가르치기"의 생략

한글을 데이터로 가르치는 비용을 백본 교체로 생략함. 이미 한국어를 아는 뇌에 소리 처리만 붙이는 전략.

항목	HELIUM (원본)	QWEN3-8B (KMOSHI)
주 대상 언어	영어 중심	한국어 / 일본어 능력 보유
텍스트 vocab	32k	151k
Hidden 차원	4096	4096 · 정확히 일치 > 오디오 임베딩 무변환 이식 가능

Helium > Qwen3-8B: "한글 가르치기"의 생략



오디오 RVQ 임베딩 추가 + Moshi 값 초기화

01 오디오 RVQ 임베딩 추가.

Qwen3에 소리 번호(0~2047)를 벡터로 바꾸는 "사전" 16권(어시 + user 각 8권, 2049×4096)을 새로 부착.

02 Moshi 값 초기화.


새 사전 16권을 백지 대신 **원본 Moshi LM의 학습값**으로 채워 출발 / 4096차원 일치로 무변환 복사.

이 과정에서, User와 Assistant로 나뉘어져 있던 Audio Embedding을 통합하는 설계로 변경!


03 검토점 > ablation.

Moshi 값은 다른 백본(Helium)에 맞춰 학습된 것 · 크기가 같아도 의미 체계가 다를 수 있음 > **Moshi값 vs random** 비교.

입력 오디오 임베딩과 출력 오디오 임베딩의 통합 구조 (제안)



입력 오디오 임베딩과 출력 오디오 임베딩의 통합 구조 (제안)



무엇을, 왜, 어떻게 증류하는가

01 · 영어 멀티턴 (KD)

"언제 말할지"를 가르친다

Teacher = 원본 Moshi.
스테레오 대화에서 뽑아낸 오디오 RVQ 로짓을 offline dump.
담당: 턴 구조 · 발화 타이밍.

02 · 한국어 싱글턴 TTS

"무슨 소리로 말할지"를 가르친다

모노 발화 · GT 코드 CE loss.
담당: 한국어 말소리 · 내용.


What? Teacher(원본 Moshi)의 오디오 RVQ 로짓만 증류 · 프레임당 8코드북 × 2048. 텍스트 로짓 제외.

Why? Mimi 공유 > 오디오 토큰 공간 동일(KL 성립). 텍스트는 vocab 32k vs 151,936 불일치 · 영어 오염. 타이밍은 이진 PAD·EPAD 타깃으로 대체.

How? **Offline 수집**: teacher를 학습 중 GPU에 안 올림. 사전 1-pass로 top-k 로짓 덤프 > student만 로드, 7B 뭉 VRAM 절약.

Loss 프레임·코드북별 KL + temperature, **semantic 코드북 가중**(타이밍 주채널).

무엇을, 왜, 어떻게 증류하는가



전제: teacher와 student가 같은 Mimi 코텍을 공유 → 오디오 토큰 공간 동일 = 로짓 KL 성립

점선: KD loss의 그래디언트가 student로 역전파 · student 로짓과 덤프 로짓을 프레임 단위 비교

두 그래디언트를 섞어 한국어 멀티턴 창발 유도

$$L = L_{\text{EN-KD}} + L_{\text{KO-TTS-CE}} + \lambda \cdot L_{\text{text-anchor}}$$

영어가 주는 **턴 구조** 그래디언트와 한국어가 주는 **말소리** 그래디언트를 한 모델에서 섞는다.

학습 데이터에 존재한 적 없는 조합(한국어 × 멀티턴)을 **두 축의 합성**으로 유도 => 이 연구의 도박이자 기여.

통제 두 task의 **loss scale · gradient norm** 실시간 모니터링 > 한쪽이 지배하지 않도록 재가중.

가중 침묵·발화 **클래스 불균형 가중**으로 "항상 침묵" 붕괴 방지.

보호 소량 **텍스트 anchor**로 순수 텍스트 능력 망각(catastrophic forgetting) 방지.

한국어와 영어의 조인트 학습 시점 판단

언제 섞느냐에 따라 백본의 편향이 결정되기 때문에 매우 중요한 포인트!

너무 늦으면 굳고, 너무 이르면 흩어지기 때문.

기각안 A

완전 순차 (영어 완성 > 한국어)

턴테이킹 회로가 영어 조건부로 고착된 뒤 > 재배선 실패
(critical period 놓침).

기각안 B

Step-0 완전 조인트

두 신호 모두 노이즈일 때 섞이면 상쇄 > 아무 회로도 안 자
람.

채택

짧은 워밍업 > 조기 조인트

모달리티만 부트스트랩한 뒤, 턴테이킹 회로가 본격 형성되
기 전에 한국어를 이미 넣어둬م..

준비 > 영어 워밍업 > 조기 조인트

Phase 0 학습 전	임베딩 추가·초기화 · 텍스트 anchor 데이터 · 진단 프로빙셋 준비.
Phase 1 전체 스텝의 5~10 %	영어 KD 단독. 목적은 영어 마스터가 아니라 "오디오 토큰 생성" 모달리티 부트스트랩. 코드북 임베딩은 짧은 freeze · 저 lr warmup. 종료 조건: 오디오 토큰이 붕괴하지 않는 모달리티 안정성.
CP · A	한국어 오디오 프리픽스에 turn-taking 내부 표현이 활성화되는지 프로빙(학습 미반영).
Phase 2 CRITICAL PERIOD	영어 KD + 한국어 TTS 조인트 진입. 한국어 비율 10 > 30 > 50 % 램프업. 영어 일부를 싱글턴처럼 잘라 언어-턴구조 상관 완화.
CP · B	영어 held-out 멀티턴 성능 급락 여부(간섭 감시) + 한국어 프로빙 재측정.

본 학습

Phase 3

본 학습

한국어 비율 목표치 유지

3지표 동시 트래킹 · 하나라도 무너지면 loss weight 재조

A

영어 멀티턴 유지력

B

한국어 창발 턴테이킹 품질

C

순수 텍스트 능력 (anchor)

CP · C

한국어 멀티턴 창발 1차 판정. 메커니즘(타이밍·오버랩)과 내용(의미 일관성)을 분리 평가.

일본어 전이 > Ablation

Phase 4 별도 브랜치	일본어 데이터 스윙 0 h > 1 h > 10 h > 100 h · J-Moshi(60k h 학습) 대비 데이터 효율 비교. 본 트랙 오염 방지 위해 분리 실행.
Phase 5 ABLATION	커리큘럼 타이밍(완전 순차 · step-0 조인트 · 워밍업+조기조인트) / 코드북 init vs random / KD 방식(teacher-forcing vs on-policy).

우선순위 — 본 트랙 Phase 0~3 완주가 최우선, 일본어와 ablation은 그 위에 얹는 서브 기여.

학습 문제 해결을 위한 교대 근무 시간표 설정

근무표 양식

팀원		7월															합계		
		13	14	15	16	17	18	19	20	21	22	23	24	25	26	27	D	E	N
문채운		O	O	D	E	N	O	N	O	D	E	D	N	O	N	O	3	2	4
김동언		D	E	O	O	D	N	O	E	O	O	E	D	N	O	E	3	4	2
신해솔		N	N	N	N	O	O	O	N	N	N	N	O	O	O	N	0	0	9
박연진		O	D	E	D	O	D	E	D	O	D	O	O	D	E	O	6	3	0
서주연		E	O	O	O	E	E	D	O	E	O	O	E	E	D	D	3	6	0
합계	D	1	1	1	1	1	1	1	1	1	1	1	1	1	1	1			
	E	1	1	1	1	1	1	1	1	1	1	1	1	1	1	1			
	N	1	1	1	1	1	1	1	1	1	1	1	1	1	1	1			
	O	2	2	2	2	2	2	2	2	2	2	2	2	2	2	2			

D주간근무 7~15

E오후근무 15~23

N야간근무 23~7

O휴무

1. 근무는 대문자로 D, E, N, O를 사용해서 입력합니다.

2. 우측의 합계는 근무수 합계를 나타냅니다.

3. 아래의 합계는 일자별 근무수 합계를 나타냅니다.

체크포인트 A / B / C – 창발을 반증 가능하게 만드는 장치

창발은 주장이 아니라 측정 대상. 세 체크포인트가 각 단계에서 가설을 반증할 기회를 만듦.

CP · A

사전 신호

Phase 1 후 · 학습 미반영 프로빙 · 한국어 프리픽스에 turn-taking 내부 표현이 잠재하는지.

CP · B

간접 감시

Phase 2 중 · 영어 held-out 성능 급락 여부 · 한국어 프로빙 재측정.

CP · C

창발 판정

Phase 3 후 · 한국어 멀티턴 창발 1차 판정.

분리 평가 · 측 1

메커니즘 전이

gap 타이밍 · 오버랩 · 맞장구 발생률. "언제 말하는가"의 통계.

분리 평가 · 측 2

내용 전이

의미 일관성 · 응답 관련성. "무엇을 말하는가"의 품질.

실패 기전 5가지와 대응

실패 기전		감시 · 대응
01	언어-태스크 shortcut 상관 — "한국어이면 반이중처럼" 학습	영어 일부를 싱글턴처럼 잘라 배치 > 언어와 톰 구조 상관 완화
02	Joint loss 그래디언트 지배	Norm 모니터링 · loss weight 재조정
03	"듣기 + 말하기 동시성"이 한국어에서 미훈련 (아키텍처 대응 실패)	프로빙으로 감시 (CP · A, B)
04	타이밍은 되지만 내용이 안 되는 부분 실패	메커니즘 / 내용 분리 평가 (CP · C)
05	RVQ 코드북 초기화가 지역해로 유도	Init ablation (Moshi값 vs random)

VRAM 관리 - 왜 ZeRO-2를 선택했나

풀 파인튜닝 9.15B 파라미터 기준 · A100 80 GB × 4 전제.

전략	GPU당 VRAM	판정
DDP	146.5 GB	불가 · 80 GB 한도 초과
FSDP 2 (ZeRO-2) 채택	50.3 GB	가능 · gradient checkpointing 필수
FSDP (ZeRO-3)	36.6 GB	폴백 · 통신 비용 상승 감수

Model Freeze 정책

구분	대상	비고
Optimizing	Qwen3 백본	본 학습 대상
Optimizing	오디오 임베딩 16권 (2049 × 4096)	초반 warmup (짧은 freeze · 저 lr)
Optimizing	Depformer 일체	학습 PHASE 마다 다르게 처리
Feezed	텍스트 임베딩 · head	텍스트 anchor 유지용
Feezed	Mimi 코덱 (RVQ 256차원 코드북)	절대 수정 금지 - 토큰 의미 변형 > KD 붕괴
Undetermined	depformer_text_emb 재구축 (Qwen vocab 종속)	Ablation으로 확정 예정
Undetermined	PAD · EPAD 토큰 매핑	Qwen 특수 토큰 슬롯 사용 후보
Undetermined	Depformer warm-start 여부	Random init vs 원본 Moshi 이식 비교